Đề xuất đề tài paper Q1: AI × Hóa dược – Hóa sinh

.

Mở đầu và lưu ý thẳng thắn

Tài liệu này đề xuất 5 đề tài AI × hóa dược – hóa sinh phù hợp người nền IT/AI, kèm cải tiến cụ thể, dữ liệu công khai, thiết kế thí nghiệm và tạp chí mục tiêu.

Ba điều cần biết trước khi chọn:

- **"Chưa ai làm" không thể đảm bảo tuyệt đối.** Mảng AI cho thuốc ra hàng trăm preprint mỗi tháng. Mỗi đề tài dưới đây nhắm vào một khoảng trống còn thưa, nhưng bạn phải tự rà soát lại (checklist ở cuối) ngay trước khi làm và trước khi nộp.
- **Q1 không có đề tài "dễ".** Đề tài dễ *thực hiện* thường là đề tài có dữ liệu công khai, benchmark rõ ràng và đóng góp phương pháp kiểm chứng được. Reviewer Q1 sẽ hỏi: so với baseline mạnh nhất chưa, chia dữ liệu có rò rỉ không, kết quả có ý nghĩa hóa học/sinh học không.
- **Nên có đồng tác giả ngành Dược/Hóa.** Họ giúp diễn giải kết quả, chọn case study, và nếu có thể làm docking/MD hoặc thử nghiệm nhỏ để xác thực. Paper có bất kỳ xác thực thực nghiệm nào đều vượt trội hơn paper thuần tính toán.

Lưu ý: danh sách Q1 trong tài liệu dựa trên xếp hạng phổ biến gần đây; hãy kiểm tra lại trên SCImago (scimagojr.com) theo đúng chuyên mục và năm trước khi nộp.

Bối cảnh và bốn khoảng trống đang mở

Năm 2026, AI cho khám phá thuốc đang ở giai đoạn "đối chứng": hơn 170 chương trình thuốc thiết kế bởi AI đã vào thử lâm sàng nhưng chưa thuốc nào được FDA phê duyệt đầy đủ. Vì vậy reviewer đang ưu tiên các bài **tăng độ tin cậy** của dự đoán hơn là tăng thêm vài điểm AUC trên benchmark cũ.

Bốn khoảng trống có thể khai thác bằng năng lực IT/AI, không cần phòng thí nghiệm ướt:

1. **Rò rỉ dữ liệu trong benchmark.** Một kiểm toán năm 2026 trên 51 cấu hình benchmark từ Polaris, Therapeutics Data Commons, MoleculeNet và các bộ DTI cho thấy nhiều bộ tưởng là đáng tin lại có lỗi ẩn, đặc biệt là trùng lặp protein giữa các tập chia (Chem. Sci. 2026). Các nghiên cứu DTI cũng chỉ ra mô hình transductive đạt điểm gần tối ưu chủ yếu nhờ rò rỉ (arXiv 2311.12670).

2. **Mô hình nền co-folding chưa đủ độ phân giải năng lượng.** Đánh giá độc lập Boltz-2 trên 16.780 hợp chất 3CLPro và 21.702 hợp chất TNKS2 kết luận mô hình nhanh nhưng thiếu độ phân giải năng lượng cho giai đoạn xác định lead (Wan et al., 2026). Các hạn chế khác được ghi nhận: nén khoảng phân bố ái lực, kém trên đích ngoài phân bố, không nhạy với đột biến nhỏ tại túi gắn và không xử lý được activity cliff (tổng hợp Boltz-2).
3. **Tác tử LLM thiếu chuẩn đánh giá.** Tổng quan trên Drug Discovery Today (2026) về AI agent trong khám phá thuốc nêu đích danh các vấn đề độ tin cậy hệ thống và benchmark (Drug Discov. Today 2026).
4. **Dữ liệu dược liệu bản địa chưa được khai thác bằng phương pháp hiện đại.** VietHerb — cơ sở dữ liệu dược liệu Việt Nam của ĐH Quốc tế, ĐHQG-HCM — có 2.881 loài, 10.887 chất chuyển hóa và 8.046 tác dụng trị liệu (Database Commons). Các bài khai thác nó phần lớn dừng ở GCN cơ bản từ 2018 (ICMLSC 2018).

Đây là lợi thế địa phương của bạn: dữ liệu dược liệu Việt Nam là thứ nhóm nước ngoài khó tiếp cận và khó diễn giải.

Đề tài 1 — Lớp hiệu chỉnh có bảo đảm thống kê cho mô hình co-folding (Boltz-2) trong sàng lọc ảo

Tên tạm: *Calibrated co-folding: Mondrian conformal correction turns Boltz-2 affinity scores into decision-ready intervals.*

Khoảng trống. Boltz-2 dự đoán ái lực nhanh nhưng đầu ra là một số điểm không kèm độ tin cậy, bị nén khoảng giá trị và suy giảm mạnh trên đích ngoài phân bố. Nhóm dùng thực tế cần biết *nên tin dự đoán nào*, không phải một bảng xếp hạng không chắc chắn. Chưa có bài nào đóng gói việc hiệu chỉnh này thành một lớp hậu xử lý dùng chung cho các mô hình co-folding.

Cải tiến đề xuất.

1. **Mondrian conformal theo nhóm protein.** Chia không gian đích thành nhóm (theo họ Pfam hoặc cụm đồng nhất trình tự 40%), hiệu chỉnh riêng từng nhóm để bao phủ đúng mức cho cả nhóm hiếm, thay vì bao phủ trung bình toàn cục.
2. **Mô hình dư (residual model) nhẹ.** Huấn luyện gradient boosting dự đoán sai số của Boltz-2 từ đặc trưng rẻ: điểm tin cậy nội bộ của mô hình, độ phân tán RMSD giữa các seed, khoảng cách Tanimoto tới tập huấn luyện, độ tương đồng trình tự đích. Băng ghế dự bị: mô hình dư không cần huấn luyện lại Boltz-2, chạy được trên 1 GPU.
3. **Dự đoán có chọn lọc (selective prediction).** Báo cáo đường cong risk–coverage: bỏ bao nhiêu phần trăm dự đoán thì sai số còn lại giảm bao nhiêu — chính là con số nhóm sàng lọc cần.

Dữ liệu. ChEMBL (chuẩn hóa pChEMBL), BindingDB, PDBbind, các bộ FEP benchmark công khai. Có sẵn bộ benchmark ngoại từ ChEMBL v35 dành riêng cho Boltz-2 để đối chiếu (Chem-Bio Informatics J. 2026).

Thiết kế thí nghiệm. Chia theo cụm (protein-blind, scaffold, temporal) — không dùng chia ngẫu nhiên. Baseline bắt buộc: Boltz-2 thô, deep ensemble, MC-dropout, conformal toàn cục, và một mô hình ligand-only (Chemprop/Uni-Mol). Kiểm định ý nghĩa: bootstrap 1.000 lần, báo cáo khoảng tin cậy.

Chỉ số. Coverage và độ rộng khoảng theo từng nhóm, ECE, Spearman theo đích, enrichment factor tại 1% và 5%, AUC của đường risk–coverage.

Rủi ro và cách gỡ. Nếu Boltz-2 quá nặng, thay bằng Boltz-1x hoặc Chai-1 và giữ nguyên đóng góp phương pháp; lớp hiệu chỉnh là đóng góp, không phải mô hình nền.

Tạp chí: Journal of Chemical Information and Modeling; Briefings in Bioinformatics; Journal of Cheminformatics.

Thời gian ước tính: 4–6 tháng, 1 GPU 24 GB trở lên.

Đề tài 2 — Học đa nhiệm có tri thức dược học cổ truyền cho dược liệu Việt Nam

Tên tạm: *Ethnopharmacology-informed multi-task learning for multi-target screening of Vietnamese medicinal plant metabolites.*

Khoảng trống. VietHerb chứa 10.887 chất chuyển hóa và 8.046 tác dụng trị liệu ghi theo y học cổ truyền, nhưng các nghiên cứu khai thác nó chủ yếu là phân loại đơn nhiệm. Quan trọng hơn: chưa ai dùng *chính nhãn công dụng dân gian* làm tín hiệu giám sát yếu (weak supervision) để hỗ trợ dự đoán hoạt tính trên đích phân tử. Đây là đóng góp liên ngành đúng nghĩa: tri thức bản địa thành prior thống kê.

Cải tiến đề xuất.

1. **Prior từ công dụng dân gian.** Ánh xạ 8.046 mô tả công dụng sang thuật ngữ MeSH/ATC bằng LLM có kiểm duyệt thủ công trên mẫu, rồi dùng làm nhiệm vụ phụ trong mạng đa nhiệm. Nhiệm vụ chính vẫn là hoạt tính đo được từ ChEMBL.
2. **Backbone hiện đại.** Fine-tune một mô hình nền phân tử (MolFormer, Uni-Mol2 hoặc ChemBERTa-2) thay cho GCN, có adapter riêng cho từng đích.
3. **Hiệu chỉnh thiên lệch phân bố.** Hợp chất tự nhiên khác phân bố với thư viện tổng hợp (nhiều vòng, nhiều tâm lập thể). Dùng importance weighting hoặc domain-adversarial training và báo cáo riêng kết quả trên phân nhóm hợp chất tự nhiên.

4. **Xác thực hai tầng.** Top-20 dự đoán được kiểm lại bằng docking (AutoDock Vina/Smina) và MD ngắn 50–100 ns với MM-GBSA. Có được một thử nghiệm ức chế enzyme in vitro từ khoa Dược thì bài báo lên hạng rõ rệt.

Dữ liệu. VietHerb, ChEMBL, COCONUT (hợp chất tự nhiên), LOTUS, NPASS. Đối chiếu cách làm với các CSDL thảo dược khác như Sanjeevani (2026) để làm rõ khác biệt.

Thiết kế thí nghiệm. Chọn 3–5 đích có dữ liệu dồi dào và gắn bệnh phổ biến ở Việt Nam: α-glucosidase và DPP-4 (tiểu đường type 2), AChE (Alzheimer), COX-2 (viêm), NS5B/NS3 (viêm gan). Chia theo scaffold và theo loài thực vật (không để hai chất cùng loài nằm hai bên). Ablation bắt buộc: bỏ nhiệm vụ prior dân gian để chứng minh prior thực sự có ích.

Chỉ số. PR-AUC và BEDROC (α=20) cho dữ liệu mất cân bằng, enrichment factor 1%, độ đồng thuận giữa xếp hạng ML và điểm MM-GBSA.

Rủi ro. Chất lượng ánh xạ công dụng → thuốc thử là để chuyên gia dược liệu kiểm định ngẫu nhiên 300 cặp và báo cáo độ đồng thuận Cohen's κ — đây cũng là một đóng góp phụ.

Tạp chí: Journal of Ethnopharmacology; Phytomedicine; Computers in Biology and Medicine; Journal of Cheminformatics.

Thời gian ước tính: 5–7 tháng. Cần ít nhất một đồng tác giả ngành Dược liệu.

Đề tài 3 — Tác tử LLM có kiểm chứng cơ chế cho tái định vị thuốc, đánh giá theo mốc thời gian

Tên tạm: *Can an LLM agent justify what it recommends? A mechanism-verified, time-split benchmark for drug repurposing.*

Khoảng trống. Tác tử LLM đang được dùng cho tổng hợp tài liệu, dự đoán độc tính và tái định vị thuốc, nhưng chưa có chuẩn đánh giá kiểm được độ tin cậy — đây là hạn chế được nêu thẳng trong tổng quan Drug Discovery Today 2026. Phần lớn bài hiện nay đánh giá bằng cách hỏi GPT chấm điểm GPT, hoặc chọn vài case study đẹp.

Cải tiến đề xuất.

1. **Đánh giá tiền cứu giả lập (retrospective-prospective).** Cắt toàn bộ tri thức tại mốc 31/12/2021: cho tác tử chỉ được truy xuất tài liệu và đồ thị tri thức trước mốc đó, rồi đo khả năng dự đoán các cặp thuốc–bệnh thực sự được phê duyệt hoặc vào pha II/III trong 2022–2026. Đây là thiết kế đánh giá nghiêm túc mà rất ít bài LLM-agent làm được.
2. **Bộ kiểm chứng cơ chế.** Mỗi đề xuất phải kèm một đường đi trên đồ thị tri thức (thuốc → đích → đường tín hiệu → bệnh). Một module riêng kiểm từng cạnh có bằng chứng trong DrugBank/OpenTargets/Reactome hay không, và loại bỏ đề xuất có cạnh bịa. Tỷ lệ cạnh bịa chính là một chỉ số của bài báo.

3. **So sánh có đối chứng.** Baseline: đồ thị tri thức thuần túy (TxGNN, nhúng KG như TransE/ComplEx), LLM không có truy xuất, LLM có RAG nhưng không có kiểm chứng. Ablation từng thành phần.

Dữ liệu. PubMed/PMC OA (cắt theo ngày), DrugBank, OpenTargets, Hetionet/PrimeKG, ClinicalTrials.gov, danh sách phê duyệt FDA/EMA 2022–2026 làm ground truth.

Chỉ số. Hit rate@K trên tập phê duyệt sau mốc, MRR, tỷ lệ cạnh cơ chế không kiểm chứng được, chi phí token trên mỗi đề xuất đúng, đánh giá mù của 2 dược sĩ trên 50 đề xuất top.

Rủi ro. Rò rỉ tri thức từ trọng số LLM (mô hình đã biết các phê duyệt 2022–2026). Gỡ: dùng mô hình mã nguồn mở có mốc cắt tri thức sớm, báo cáo thêm điểm trên tập kiểm định tri thức bị che, và thảo luận giới hạn này công khai — reviewer đánh giá cao sự trung thực này.

Tạp chí: Briefings in Bioinformatics; Journal of Biomedical Informatics; Drug Discovery Today; npj Digital Medicine (khó hơn).

Thời gian ước tính: 4–6 tháng. Chi phí API là biến số cần tính trước.

Đề tài 4 — Dự đoán vị trí chuyển hóa đặc hiệu từng isoform CYP450

Tên tạm: *Isoform-conditioned site-of-metabolism prediction by coupling a molecular graph with a protein language model.*

Khoảng trống. Hầu hết mô hình dự đoán vị trí chuyển hóa (site of metabolism, SoM) chỉ nhìn phân tử thuốc, hoặc huấn luyện một mô hình riêng cho mỗi isoform. Trong khi đó CYP1A2, 2C9, 2C19, 2D6 và 3A4 có túi gắn khác hẳn nhau, và đa hình di truyền (CYP2C19*2, CYP2D6*10 — rất phổ biến ở người châu Á) làm thay đổi chuyển hóa. Chưa có mô hình SoM nào nhận trình tự enzyme làm đầu vào để tổng quát hóa sang biến thể chưa thấy.

Cải tiến đề xuất.

1. **Điều kiện hóa theo enzyme.** Nhúng trình tự CYP bằng ESM-2 hoặc ProtT5, kết hợp với biểu diễn đồ thị phân tử qua cross-attention ở mức nguyên tử. Một mô hình duy nhất phục vụ mọi isoform.
2. **Kiểm tra tổng quát hóa zero-shot.** Giữ lại một isoform hoàn toàn ngoài tập huấn luyện rồi dự đoán — đây là bài kiểm tra chưa xuất hiện trong văn liệu SoM và là điểm bán của bài báo.
3. **Ràng buộc hóa học.** Thêm đặc trưng năng lượng tách hydro (BDE) tính bằng xTB hoặc tra từ bảng, và độ tiếp cận bề mặt nguyên tử, để mô hình không học tắt theo mẫu scaffold.

4. **Diễn giải đối chiếu được.** Bản đồ attention ở mức nguyên tử được so với vị trí chuyển hóa đã biết — định lượng, không chỉ đẹp mắt.

Dữ liệu. MetaQSAR, Zaretzki/SoM dataset, DrugBank metabolism, MetXBioDB, Metabolite và cấu trúc CYP từ PDB. Trình tự biến thể lấy từ PharmVar.

Thiết kế thí nghiệm. Chia theo scaffold và theo isoform. Baseline: FAME 3, SMARTCyp, XenoSite, một GNN huấn luyện riêng cho từng isoform. Báo cáo riêng trường hợp phân tử có nhiều vị trí chuyển hóa.

Chỉ số. Top-1 và Top-2 accuracy (chuẩn của lĩnh vực SoM), MCC ở mức nguyên tử, hiệu năng zero-shot trên isoform bị giữ lại.

Ý nghĩa lâm sàng. Gắn trực tiếp với tương tác thuốc–thuốc và dược di truyền học — phần "so what" rất dễ viết thuyết phục, điểm yếu thường gặp của paper thuần AI.

Tạp chí: Journal of Chemical Information and Modeling; Chemical Research in Toxicology; Computational and Structural Biotechnology Journal; Journal of Cheminformatics.

Thời gian ước tính: 4–5 tháng. Đây là đề tài ít rủi ro kỹ thuật nhất trong năm đề tài.

Đề tài 5 — Benchmark không rò rỉ và baseline bền với dịch chuyển phân bố cho dự đoán ái lực

Tên tạm: *How much of our progress is leakage? A leakage-audited benchmark and shift-robust baseline for drug–target affinity.*

Khoảng trống. Kiểm toán năm 2026 cho thấy các bộ benchmark được trích dẫn hàng nghìn lần vẫn có rò rỉ chưa được xử lý. Các công cụ như DTA-GNN đã bắt đầu tự động hóa việc kiểm rò rỉ, nhưng chưa ai trả lời được câu hỏi định lượng: *trong 10 năm tiến bộ báo cáo của lĩnh vực, bao nhiêu phần là thật?*

Cải tiến đề xuất.

1. **Tái đánh giá có hệ thống.** Chạy lại 10–15 mô hình DTA có mã công khai (DeepDTA, GraphDTA, MolTrans, PerceiverCPI, mô hình nền phân tử, Boltz-2) trên cùng một bộ chia nghiêm ngặt. Vẽ đường cong "hiệu năng báo cáo theo năm" so với "hiệu năng sau khi loại rò rỉ". Kết quả khả dĩ: đường thứ hai phẳng hơn nhiều — một phát hiện đáng đăng.
2. **Chia dữ liệu ba trục.** Cụm ligand (Butina/Bemis–Murcko), cụm protein (MMseqs2 ở 30% và 50%), và chia theo thời gian theo năm công bố trong ChEMBL. Báo cáo đầy đủ ma trận ba trục thay vì một con số.
3. **Baseline bền vững.** Đề xuất một baseline kết hợp group DRO (distributionally robust optimization) theo họ protein với hiệu chỉnh conformal, chứng minh nó giữ hiệu năng tốt hơn khi dịch chuyển phân bố tăng.

4. **Sản phẩm công khai.** Phát hành bộ chia, mã, và báo cáo kiểm rò rỉ dưới dạng gói pip. Bài dạng tài nguyên như thế rất dễ được trích dẫn.

Vì sao dễ submit. Không cần phát minh kiến trúc mới, không cần thí nghiệm ướt, tiêu chí chấp nhận rõ ràng (tính đầy đủ, tính tái lập). Đây là đề tài phù hợp nhất nếu bạn làm một mình và muốn ra bài trong 4 tháng.

Rủi ro. Tốn công sức kỹ thuật để chạy lại mã cũ (phụ thuộc hỏng, thiếu checkpoint). Gỡ: giới hạn ở 8–10 mô hình còn chạy được và nói rõ tiêu chí loại trừ. Rủi ro thứ hai: có nhóm khác đang làm việc tương tự — hãy thu hẹp vào một họ đích cụ thể (kinase, GPCR, protease) để khác biệt hóa.

Tạp chí: Journal of Cheminformatics; Briefings in Bioinformatics; Scientific Data; Bioinformatics.

Thời gian ước tính: 3–5 tháng.

So sánh và khuyến nghị

Nếu bạn làm một mình và chưa có cộng tác viên ngành Dược, hãy bắt đầu bằng Đề tài 5, rồi dùng chính bộ benchmark đó làm nền cho Đề tài 1 — hai bài nối tiếp nhau rất tự nhiên.

Đề tài	Độ mới	Độ khó kỹ thuật	Tài nguyên tính toán	Cần cộng tác Dược	Thời gian	Rủi ro bị "cắt mặt"
1. Hiệu chỉnh co-folding	Cao	Trung bình	Cao (GPU 24 GB+)	Không bắt buộc	4–6 tháng	Trung bình
2. Dược liệu Việt Nam	Cao (lợi thế địa phương)	Trung bình	Trung bình	Có, quan trọng	5–7 tháng	Thấp
3. Tác tử LLM tái định vị	Cao	Cao	Thấp (chủ yếu chi phí API)	Nên có cho phần đánh giá	4–6 tháng	Cao
4. SoM đặc hiệu CYP	Trung bình–cao	Trung bình	Trung bình	Không bắt buộc	4–5 tháng	Trung bình
5. Benchmark không rò rỉ	Trung bình (giá trị nằm ở độ kỹ lưỡng)	Thấp–trung bình	Trung bình	Không	3–5 tháng	Cao

Một lưu ý về cột cuối: đề tài 3 và 5 đang "nóng", nên nếu chọn thì phải đi nhanh và đăng preprint sớm để xác lập mốc thời gian. Đề tài 2 an toàn nhất về mặt cạnh tranh vì dữ liệu là thế mạnh riêng của bạn.

Tạp chí Q1 phù hợp

Các tạp chí dưới đây quen thuộc với bài AI × hóa dược và có reviewer hiểu cả hai phía. Hãy tự xác nhận hạng trên SCImago trước khi nộp.

Tạp chí	Nhà xuất bản	Phù hợp đề tài	Ghi chú
Journal of Chemical Information and Modeling	ACS	1, 4	Chuẩn mực, reviewer khắt khe về baseline
Journal of Cheminformatics	Springer	1, 4, 5	Open access, ưu ái bài có mã nguồn tốt
Briefings in Bioinformatics	Oxford	1, 3, 5	Thích bài benchmark và so sánh hệ thống
Computers in Biology and Medicine	Elsevier	2, 4	Chu kỳ phản biện nhanh hơn
Journal of Ethnopharmacology	Elsevier	2	Bắt buộc phần diễn giải dược học vững
Computational and Structural Biotechnology Journal	Elsevier	1, 4	Open access, phạm vi rộng
Scientific Data	Nature Portfolio	5	Chỉ nhận bài dạng dữ liệu/tài nguyên

Nguồn đã tham khảo

- Auditing widely used biomolecular benchmarks reveals systematic data inconsistencies — Chemical Science, 2026
- On the Reliability of AI Methods in Drug Discovery: Evaluation of Boltz-2 — Wan et al., 2026
- ChEMBL-Derived Benchmark Dataset for Boltz-2 Binding Affinity Prediction — Chem-Bio Informatics Journal, 2026
- Tổng hợp hạn chế của Boltz-2
- DTI benchmarking và rò rỉ dữ liệu — arXiv 2311.12670
- DTA-GNN toolkit — 2026
- AI agents in drug discovery: applications and case studies — Drug Discovery Today, 2026
- VietHerb — Database Commons
- Graph convolution cho hợp chất chống ung thư từ VietHerb — ICMLSC 2018
- Sanjeevani: anti-cancerous phytochemical database — bioRxiv, 2026
- AI in drug discovery: predictions for 2026 — Drug Target Review

Tên repo: 1.conformal-cofolding, 2.vietherb-mtl, 3.repurpose-verify, 4.isoform-som, 5.leakfree-dta